CIDESI POSGRADO INTERINSTITUCIONAL EN CIENCIA Y TECNOLOGÍA

RESTAURACIÓN GEOMÉTRICAMENTE CONSISTENTE Y CALIBRACIÓN ADAPTATIVA DE CÁMARAS SUBMARINAS

TESIS

QUE PARA OBTENER EL GRADO ACADÉMICO DE:

MAESTRO EN CIENCIA Y TECNOLOGÍA EN MECATRÓNICA

Presenta:

Gabriel Rodríguez Feregrino

Director de Tesis: Dr. Tomas Salgado Jiménez
Codirector / Asesor: Dr. Cristian Hamilton Sánchez Saquín

Santiago de Querétaro, Qro., México, Octubre 2026

Resumen

El resumen es una síntesis del trabajo final que hace hincapié en sus puntos sobresalientes. Toda la información que contiene la tesis debe estar comprendida en el resumen. El objetivo de incluirse es evitar que el lector tenga que leer todo el trabajo. Sin estos resúmenes, sería difícil para los profesionales mantenerse al día en su área. Por otra parte, este resumen puede lograr que el lector se motive a leer el informe completo. En cuanto a la redacción del resumen, este puede estar escrito en tiempo pasado, ya que es la historia del trabajo terminado, o en tiempo presente, ya que constituye la aportación global al área específica. Debe cuidar cada palabra que escriba. Es una síntesis de la tesis que destaca los puntos sobresalientes, donde no se incluye ninguna interpretación de la misma. La mejor manera de redactar un resumen es pensar en una llamada de larga distancia en la que usted relata a un amigo en que consiste su trabajo. El resumen debe contener entre 250 y 500 palabras, ocupando una sola página. Recuerde que debe ser breve. El resumen debe de incluir los siguientes puntos: La descripción del problema de una forma muy breve (pueden ser 2 proposiciones: una proposición antecedente y una proposición concluyente); una breve descripción de la solución; los objetivos y de una forma muy breve los resultados obtenidos.

Palabras clave: Calibración submarina, visión por computadora, sistemas embebidos, variación térmica, restauración espectral.

Abstract

The summary synthesizes the final work that emphasizes its salient points. All the information contained in the thesis must be included in the abstract. The purpose of inclusion is to avoid the reader having to read the entire work. Without these summaries, it would be difficult for professionals to keep up-to-date in their area. On the other hand, this summary can motivate the reader to read the full report. Regarding the writing of the summary, it can be written in the past tense, since it is the history of the completed work, or in the present tense since it constitutes the global contribution to the specific area. You must take care of every word you write. It is a thesis synthesis that highlights the salient points, where no interpretation of it is included. An excellent way to write a summary is to think of a long-distance call in which you tell a friend what your job consists of. The abstract must contain between 250 and 500 words, occupying a single page. Remember to keep it brief. The abstract must include the following points: A very brief description of the problem (there can be 2 propositions: an antecedent proposition and a conclusive proposition); a brief description of the solution; the objectives and in a very brief way the results obtained.

Keywords: Underwater calibration, computer vision, embedded systems, thermal variation, spectral restoration.

Agradecimientos

Índice general

Resumen I

Abstract III

Glosario XV

1. Introducción 1

1.1. Antecedentes 2
1.2. Definición del problema 3
1.3. Justificación 3
1.4. Objetivos 4
1.4.1. Objetivo General 4
1.4.2. Objetivos Específicos 5
1.4.3. Objetivos particulares 5
1.5. Hipótesis 6

2. Estado del Arte y Marco Teórico 7

2.1. Análisis del estado del arte 7
2.2. Descripción del marco teórico 13

3. Método o Procedimiento de Investigación 15

3.1. Descripción del método 15
3.2. Equipos, Materiales e Instrumentación 16
3.3. Diseño Experimental y Clasificación de Variables 17
3.4. Procedimiento Experimental y Procesamiento 17
3.4.1. Instrumentación de la Planta Experimental 18

3.4.2. Adquisición y Análisis Monovariable 18
3.4.3. Adquisición y Análisis Multivariable 19
3.4.4. Desarrollo del Algoritmo Adaptativo Liviano 19
3.4.5. Sistema de Medición y Reconstrucción Tridimensional 20
3.4.6. Evaluación del Desempeño 20

4. Resultados **21**
4.1. Descripción de los resultados 21

5. Conclusiones y Recomendaciones **23**
5.1. Conclusiones 23
5.2. Recomendaciones 23

6. Referencias **25**

Appendices **29**

Apéndice A. Formato y Contenido de Tesis **31**

Declaración de Autoría **33**

Índice de figuras

Índice de tablas

2.1. Evolución de métodos físicos y tradicionales de restauración subacuática. 9
2.2. Papers y variables usadas por redes neuronales. 12

Índice de listados

Glosario

El glosario es un catálogo de palabras como un antecedente a sus definiciones a lo largo del texto, pero también como una forma fácil de revisar de una forma rápida sus definiciones.

AUV Autonomous Underwater Vehicle (Vehículo Submarino Autónomo).

CIP Channel Intensity Prior.

DCP Dark Channel Prior.

IA Inteligencia Artificial.

ROV Remotely Operated Vehicle (Vehículo Operado Remotamente).

1 Introducción

La visión subacuática tiene dos fenómenos físicos interconectados que la restringen: la distorsión geométrica causada por el efecto de refracción en la interfaz agua-vidrio-lente, y la degradación radiométrica, causada por la absorción y dispersión (*scattering*) de la luz en el agua (Sánchez-Saquín, Baldenegro-Pérez et al., 2025; Z. Zhang, 2000). En el marco teórico, la propagación de la luz en el fluido hace que el modelo de cámara estenopeico (*pinhole*) estándar no sea válido, por lo que es necesario considerar explícitamente las variables y propiedades ópticas del medio, como la ley de Lambert-Beer y la variación espectral de los coeficientes de atenuación según la longitud de onda, para lograr tanto la restauración de la calidad cromática como una calibración métrica consistente (W. Zhang et al., 2023; Zhou, Wang et al., 2023).

A lo largo de la historia, la investigación se ha centrado y evolucionado a través de 2 vertientes: por un lado, los modelos físicos y tradicionales, que comenzaron usando modelos rígidos centrados en la corrección por refracción (Z. Zhang, 2000) o utilizando *priors* atmosféricos terrestres como el *Dark Channel Prior* (DCP) (Ke et al., 2023; W. Zhang et al., 2023), y con el tiempo evolucionaron hacia el modelado espectral explícito de curvas y desacoplamiento de fenómenos ópticos en espacios de color. Sin embargo, estos enfoques tomaron el medio como estático, causando serios problemas con luz artificial intensa o regiones sin textura.

Por otro lado, las redes neuronales y el aprendizaje profundo han sido incorporados en la visión subacuática, comenzando con la síntesis de imágenes subacuáticas mediante arquitecturas tipo GAN (*WaterGAN*) (J. Li et al., 2018), y posteriormente evolucionando hacia modelos híbridos que usan variables físicas como profundidad, transmisión y *backscatter* (*UWCNN*, *Deep WaveNet*, NeRFs submarinos) (C. Li et al., 2020; Sharma et al., 2023; T. Zhang & Johnson-Roberson, 2023). Más recientemente, se han desarrollado redes neuronales de regresión y marcos de optimización probabi-

lística para la calibración implícita o directa de los parámetros intrínsecos de la cámara (Meng et al., 2024; Sánchez-Saquín et al., 2024; Zhou et al., 2025).

Aun tras todo esto, hay limitaciones técnicas no resueltas: primeramente, los métodos actuales tienen un alto consumo computacional, haciendo complicada su ejecución en sistemas embebidos de ROVs (W. Zhang et al., 2025); aparte de esto, la literatura ignora la temperatura del agua como parámetro de calibración, siendo que esta altera directamente el índice de refracción del agua y, por lo tanto, la geometría focal.

Con esto, el propósito de este trabajo es desarrollar e implementar un algoritmo robusto de calibración y restauración adaptativa para sistemas de visión submarina en vehículos ROV. Buscando compensar tanto las variaciones térmicas del agua, la atenuación o variación de componentes RGB y los cambios de iluminación, minimizando así la degradación de la imagen durante su adquisición. La validación de este sistema se realizará en un entorno controlado, siendo un tanque de agua y una alberca, evaluándolo mediante el error de reproyección, la estabilidad de los parámetros de calibración y la precisión en reconstrucción 3D, además de la medición de objetos submarinos.

1.1 Antecedentes

El interés en el desarrollo de este tema surgió a partir de 2 temas; el primero fue un problema encontrado en trabajos previamente desarrollados en visión submarina, y el segundo fue un descubrimiento reciente.

Anteriormente, durante el desarrollo de un sistema de visión para un ROV, enfocado en reconocimiento de imágenes usando redes neuronales, se confirmó que las variaciones en las condiciones de iluminación afectaban seriamente al desempeño del sistema. Esto demostró que los modelos de visión necesitan una etapa de limpieza de la imagen antes de la inferencia para disminuir este problema.

Al mismo tiempo, una investigación del Dr. Cristian Hamilton en el Centro de Ingeniería y Desarrollo Industrial (CIDESI) demostró que las propiedades del fluido no solo afectan a la estética de la imagen, sino que alteran directamente los parámetros del sistema óptico (Sánchez-Saquín et al., 2024). Específicamente, sus estudios evidenciaron que las variaciones en la temperatura del agua y en la concentración de colorantes o turbidez causan desplazamientos en la distancia focal y el error de reproyección de la cámara (Sánchez-Saquín, Baldenegro-Pérez et al., 2025).

Esto causó que investigara los antecedentes, descubriendo un área de oportunidad no explorada, debido a que la literatura actual no toma la temperatura como variable en la calibración de la cámara; por lo tanto, existe la necesidad de desarrollar algoritmos que integren el efecto de la temperatura, los componentes RGB y la iluminación artificial en un mismo sistema para la calibración de cámaras submarinas en vehículos ROV.

1.2 Definición del problema

La calibración en sistemas de visión en ROVs es algo crítico para poder garantizar exactitud en tareas como la inspección, medición subacuática y reconstrucción 3D.

La degradación en imágenes submarinas ocurre principalmente por 2 fenómenos: la distorsión geométrica por la refracción múltiple en las interfaces ópticas y la atenuación radiométrica, por la absorción y dispersión de la luz. Actualmente, los métodos de calibración tratan la geometría de la cámara y la restauración cromática en bloques independientes, o en algoritmos muy complejos y con costes computacionalmente altos para su uso embebido.

Existe evidencia reciente que ha demostrado que la temperatura del agua afecta directamente a las propiedades ópticas, debido a que varía su índice de refracción, causa desplazamientos en la distancia focal y causa errores de reproyección.

Actualmente los sistemas de calibración no toman a la temperatura como un parámetro variable, omitiendo así el efecto que esta causa en el sistema. En consecuencia, no hay un sistema de calibración de cámaras submarinas que sea adaptativo y geométricamente consistente a las variaciones de temperatura, los cambios en la iluminación y en los componentes RGB, lo que provoca un aumento en el error de reproyección y pérdida de precisión en mediciones y reconstrucción 3D.

1.3 Justificación

El desarrollo de esta investigación se justifica por su relevancia científica, tecnológica e industrial, debido a que aborda una brecha no cubierta en la visión por compu-

tadora subacuática: la degradación de la precisión métrica en sistemas de visión para vehículos ROV debido a variaciones térmicas del medio y fluctuaciones de iluminación artificial (Sánchez-Saquín, Baldenegro-Pérez et al., 2025; Sánchez-Saquín et al., 2024).

En el ámbito científico y tecnológico, se aporta un avance al integrar, en un mismo algoritmo adaptativo, la calibración geométrica y la restauración cromática considerando la temperatura del agua como parámetro. Debido a que la temperatura modifica el índice de refracción del fluido y causa desplazamientos en la distancia focal y en el punto principal del sensor (Sánchez-Saquín, Baldenegro-Pérez et al., 2025), la incorporación explícita de esta variable mejora la estabilidad de la calibración y la consistencia geométrica en reconstrucciones 3D y mediciones subacuáticas (Sánchez-Saquín et al., 2024).

Desde el punto de vista aplicado y social, los beneficiarios directos de los resultados de esta tesis incluyen:

- **La industria marítima y de inspección de infraestructura subacuática:** Empresas enfocadas en el mantenimiento e inspección no destructiva de ductos, plataformas petroleras, casco de embarcaciones e infraestructura portuaria, las cuales obtendrán mediciones métricas de mayor precisión y menor margen de error sin depender de paros operativos prolongados.
- **La investigación oceanográfica y biológica:** Científicos e instituciones marinas que requieren cuantificar y mapear estructuras tridimensionales de arrecifes y organismos bentónicos sin alterar físicamente los ecosistemas.
- **El sector de la robótica subacuática (ROVs y AUVs):** Desarrolladores e integradores de sistemas de navegación autónoma, quienes contarán con una forma de visión más robusta que mantiene su precisión de medición independientemente de las variaciones térmicas y de luz durante misiones profundas o prolongadas.

1.4 Objetivos

1.4.1 Objetivo General

Desarrollar un algoritmo robusto de calibración de cámaras subacuáticas en sistemas de visión de vehículos ROV, capaz de mantener su precisión ante variaciones en

las condiciones de adquisición de la imagen, debe considerarse de forma integrada las variaciones de temperatura del agua, la variación en componentes RGB y los cambios de iluminación, a fin de mantener la precisión métrica y la consistencia geométrica en tareas de medición y reconstrucción 3D.

1.4.2 Objetivos Específicos

- Medir la influencia de la temperatura del agua sobre el índice de refracción del medio y su impacto directo en los parámetros intrínsecos de la cámara (distancia focal, punto principal y distorsión).
- Modelar la influencia de las variaciones de los componentes RGB, la dispersión cromática (sesgo azul-verde), pérdida de gradientes, desplazamiento del punto principal y la distancia focal.
- caracterizar la influencia de las variaciones de iluminación en la imagen, como los gradientes no uniformes.
- Desarrollar un algoritmo que integre estos tres componentes para realizar una calibración adaptativa de la cámara.
- Evaluar el desempeño del algoritmo mediante la cuantificación del error de reproyección, la estabilidad de los parámetros intrínsecos y la exactitud en la medición de objetos y reconstrucción 3D.

1.4.3 Objetivos particulares

- Diseñar e instrumentar un banco de pruebas experimental controlado (tanque acuático y alberca) equipado con sensores de temperatura, monitoreo de color e iluminación regulable.
- Implementar e integrar el algoritmo desarrollado en el hardware embebido en la arquitectura del vehículo ROV académico.

1.5 Hipótesis

Un algoritmo adaptativo de calibración de cámaras de sistemas de visión subacuática que integra de manera simultánea el modelado de las variaciones térmicas del agua, la compensación de los componentes RGB y la corrección de gradientes no uniformes de las variaciones de iluminación, permite mantener la estabilidad de los parámetros intrínsecos de la cámara, reducir el error de reproyección y preservar la exactitud métrica en tareas de medición y reconstrucción tridimensional, superando en desempeño y consistencia geométrica a los métodos de calibración convencionales estáticos ante condiciones ambientales cambiantes.

2 Estado del Arte y Marco Teórico

2.1 Análisis del estado del arte

La visión subacuática tiene 2 principales desafíos, la distorsión geométrica causada por la refracción en el agua-vidrio-aire que tiene la cámara, y la degradación radiométrica (pérdida de contraste, atenuación cromática y dispersión), principalmente provocada porque el agua absorbe y dispersa la luz que recibe. Desde hace muchos años la calibración de las cámaras que se usan en entornos submarinos se realizó con modelos geométricos rígidos, que estaban centrados en la corrección por refracción, siendo el método de Zhang (Z. Zhang, 2000) el más representativo. Pero estos enfoques no toman en cuenta otros factores ambientales, como la temperatura, la salinidad, la iluminación, o incluso la interacción de la luz con el medio en sí (Sánchez-Saquín, Baldenegro-Pérez et al., 2025). Con el paso de los años estos métodos de restauración y calibración han avanzado a través de modelos físicos orientados a la física del medio, y más reciente, usando inteligencia artificial y redes neuronales.

Evolución de los Modelos Físicos y Métodos Tradicionales

Durante el periodo **2005 - 2016**, los primeros acercamientos fueron usando hardware óptico especializado, o de la adaptación directa de priors atmosféricos terrestres (el *Dark Channel Prior*) (W. Zhang et al., 2023) (Ke et al., 2023). Estos métodos funcionaban en entornos controlados, pero tenían muchas limitaciones, los priors terrestres fallaban por la absorción dependiente de la longitud de onda y la arena brillante (Berman et al., 2021).

Posteriormente, entre **2017 y 2019** se priorizó la investigación en el modelado explícito de la atenuación espectral mediante curvas de Haze-Lines y métodos de estimación de profundidad por desenfoque y absorción(IBLA) (W. Zhang et al., 2023) (Ke et al., 2023). Esto permitió considerar la degradación por longitud de onda, pero tenían problemas e ineficiencias en zonas marinas sin textura (zonas donde no se puede estimar la profundidad), aparte de que tienen una calcificación muy rígida para poder ser usada en cuerpos de agua reales y cambiantes (Ke et al., 2023) (Berman et al., 2021).

Entre **2020 y 2023** se centraron más en investigar el desacoplamiento de fenómenos ópticos. Para ello se incorporó el balance cromático adaptativo en diversos espacios de color, también la estimación del *backscatter* mediante píxeles obscuros adaptativos, modelos MCLA con ley de Lambert-Beer (Zhou, Wang et al., 2023) y balance adaptativo en espacios *Lab y CIE L*a*b** (W. Zhang et al., 2023). Los resultados tuvieron mayor fidelidad en la restauración, pero tenían una corrección deficiente cuando se usaba iluminación artificial severa, que es muy usada en ROVs y AUVs, además de generar artefactos en regiones obscuras o sobrecompensación en el canal rojo.

Recientemente en los años **2024 y 2025** surgieron modelos heurísticos avanzados como (MJPNet) (Fan et al., 2025) y filtros homomórficos acoplados a restricciones físicas con clasificación por factor de riesgo de sesgo cromático (W. Zhang et al., 2025). Sin embargo, la complejidad, el consumo computacional, y la rigidez debido a la dependencia de datasets de entrenamiento causo que sea complicado usarlos en entornos reales sobre todo en sistemas embebidos de AUVs y ROVs en tiempo real.

Tabla 2.1: Evolución de métodos físicos y tradicionales de restauración subacuática.

Periodo	Método / Modelo	Parte de interés	Variables y limitaciones principales
2005–2016	**DCP y Hardware**	Hardware óptico adaptado y priors atmosféricos terrestres	Entornos controlados; falla por absorción dependiente de λ y reflejos de arena (Berman et al., 2021; Ke et al., 2023; W. Zhang et al., 2023)
2017–2019	**Haze-Lines e IBLA**	Atenuación espectral explícita y profundidad por desenfoque/absorción	Considera atenuación por λ; colapsa en zonas sin textura y agua cambiante (Berman et al., 2021; Ke et al., 2023; W. Zhang et al., 2023)
2020–2023	**MCLA y Espacios Lab**	Desacoplamiento óptico, Lambert-Beer y píxeles oscuros adaptativos	Fidelidad cromática; falla ante luz artificial severa (ROVs/AUVs) y sobrecompensa rojo (W. Zhang et al., 2023; Zhou, Wang et al., 2023)
2024–2025	**MJPNet y Homomórfico**	Modelos heurísticos con restricciones físicas y sesgo cromático	Alta precisión; elevada carga computacional e inviable en tiempo real para embebidos (Fan et al., 2025; W. Zhang et al., 2025)

Evolución de los Modelos de Inteligencia Artificial y Redes Neuronales

La integración de redes neuronales en la visión subacuática ha seguido una línea histórica de investigación de tres fases claras: una primera etapa enfocada en la mejora de calidad de imágenes degradadas; una segunda dedicada a crear modelos híbridos que estiman variables físicas intermedias (profundidad, transmisión y *backscatter*); y una tercera etapa reciente donde las redes ejecutan calibraciones implícitas o directas sobre el sistema óptico.

En la primera fase, en los años **2017 - 2020** el principal problema para el entrenamiento de redes neuronales, fue la escasez de datos (*ground truth*) en entornos submarinos, Para ello *WaterGAN* generó imágenes subacuáticas de manera sintética, usando pares RGB-D en aire y con ello aprendió una corrección de color monocular en 2 etapas, esta fue validada en un tanque de agua, así como en campo (J. Li et al., 2018).

Entre **2018 y 2020** redes como CNN y redes residuales aparte de corregir el color, también lo hacían para *de-scattering*, *blur* y profundidad. En imágenes con baja iluminación, las redes CNN usaron una estimación de profundidad y corrección espectral para compensar el *scattering* y la perdida cromática (Lu et al., 2018). Mientras otras redes como *UWCNN* directamente empezó a hacer reconstrucción directa de la imagen latente, esta fue entrenada con datos sintéticos basados en un modelo básico, y distintos tipos de agua (C. Li et al., 2020).

Al mismo tiempo, un marco *end-to-end* añadió el enfoque de desenfoque a la base sintética debido a que la bases anteriores solo consideraban el *scattering* y la atenuación (Dudhane et al., 2020).

Durante los años **2021 - 2023** se dejó de tratar la restauración como algo desconocido, y las redes empezó a ser diseñadas según la física por canal. Redes como *Deep WaveNet* demostraron que las imágenes subacuáticas requieren tamaños de contexto distintos por canal, esto es porque la atenuación de la longitud de onda es asimétrica, además incorporo *skip connections atentas* para refinar ciertos rasgos multicontexto (Sharma et al., 2023). Él señalaba que reutilizar CNN que eran para entornos terrestres sin rediseño para entornos subacuáticos produce artefactos y color distorsionado.

Otros métodos también fueron surgiendo, como algunos que estiman la profundidad, el *backscatter*, la iluminación y coeficientes de atenuación, esto con módulos

neuronales o semi neuronales. Por ejemplo tenemos el trabajo de Zhou, que empleo prior de pixel oscuro adaptativo, combinó el modelo de formación de imagen, *Channel Intensity Prior*, la eliminación de *backscatter*, y una etapa no supervisada para reducir los efectos de usar luz artificial (Zhou, Liu et al., 2023). Otro modelo uso 2 etapas para estimar el coeficiente de atenuación, esto para guiar la restauración horizontal, luego usó un bloque de atención por prior de atenuación para recalibrar los mapas RGB en la disposición vertical (Lin et al., 2021). Al mismo tiempo, un campo de reflectancia neuronal, aprendió conjuntamente el color verdadero, la atenuación y el *backscatter* desde múltiples vistas, como la iluminación *onboard* de robots, esto sin depender de pre-entrenamiento o de mapas de profundidad obtenidos previamente (T. Zhang & Johnson-Roberson, 2023).

Finalmente, durante **2024 - 2025** el restaurar la imagen ya no es lo único que se buscaba, sino que se empezó a calibrar la cámara directamente usando redes neuronales. En 2024 un marco que fue guiado por un modelo físico de 2024 entrenó subredes separadas con el propósito de estimar la profundidad, *veiling light* y coeficientes de atenuación/*scattering*, esto fue por qué trabajos anteriores fallaban porque se invertía mucho en modelos físicos demasiado idealizados, o porque estimaban mal los parámetros anteriores (Du et al., 2026).

Específicamente en la calibración geométrica, actualmente hay 2 líneas de desarrollo, la primera usa una CNN sobre unas imágenes en el tablero para estimar directamente la matriz de calibración en agua limpia, verde y azul, obteniendo mejores resultados que Zhang y Bouguet, aparte de que valido en reconstrucción 3D (Sánchez-Saquín et al., 2024). La otra línea, en cambio, propone una calibración implícita estéreo, con una red de regresión por coordenadas y diana autoiluminada, superando a métodos explícitos en medición, postura y reconstrucción 3D (Meng et al., 2024). Existe un tercer trabajo que vincula la mejora neuronal de placas de calibración con error de re-proyección y precisa de medida, esta tiene mejor desempeño que la calibración implícita basada en datos (Zhou et al., 2025).

Para la calibración de color también se volvió más geométrico. Hay un método auto-adaptativo para aguas profundas que usa mapas de profundidad generados por SfM-MVS, zonas bien iluminadas y una FNN para restaurar el color sin tener que usar cartas de color ni información del ambiente de manera precisa, esto siempre y cuando la configuración de la cámara-luz se mantenga estable (Vlachos & Skarlatos, 2024). Este sistema aunque ya está más cerca de una calibración operativa, aun sigue dependiendo de solape suficiente y de que algunas regiones funcionen como *pseudo-ground-truth* Cromático.

Tabla 2.2: Papers y variables usadas por redes neuronales.

Año	Paper	Parte de interés	Variables tratadas
2017	**WaterGAN**	Síntesis GAN + corrección monocular	profundidad, color, scattering, tipo de agua (J. Li et al., 2018)
2020	**UWCNN**	Reconstrucción directa con prior submarino	color, scattering, absorción, tipo de agua (C. Li et al., 2020)
2021	**Deep WaveNet**	Receptive fields por longitud de onda	color por canal, contexto multiescala (Sharma et al., 2023)
2023	**NeRF Underwater**	Aprende escena y agua conjuntamente	backscatter, atenuación, iluminación, geometría (T. Zhang & Johnson-Roberson, 2023)
2023	**ADP + CIP**	Modelo físico + estimación no supervisada	profundidad, backscatter, luz artificial, balance azul-verde (Zhou, Liu et al., 2023)
2024	**DDM + UIEConv**	Estima parámetros físicos con subredes	profundidad, veiling light, atenuación/scattering (Du et al., 2026)
2024	**Implicit Stereo Calibration**	Calibración implícita por regresión	profundidad, refracción, aberración espacial, postura, 3D (Meng et al., 2024)
2024	**FNN + SfM-MVS**	Calibración cromática auto-adaptativa	color, profundidad, iluminación por estrobos (Vlachos & Skarlatos, 2024)
2025	**Probabilistic Measurement Net**	Mejora imagen para calibración y medición	color, contraste, nitidez, distorsión (Zhou et al., 2025)

A pesar de los avances documentados, esta revisión del estado de arte revela que aún hay limitaciones no resueltas hasta la fecha:

- En la literatura se vio que la mayoría de métodos contemplan la profundidad, la atenuación espectral, el *backscatter* y la dispersión, ningún modelo actual tanto físico o neuronal, contempla la temperatura del agua como parámetro dinámico, ignorar esto provoca fallos en la respuesta óptica, debido a que la variación de temperatura afecta directamente el índice de refracción del agua.
- Los métodos de calibración y restauración actuales con mayor precisión cromática y geométrica, dependen de tener una alta carga computacional, lo que imposibilita su uso en tiempo real en sistemas embebidos de ROVs y AUVs. Además de que fallan en presencia de iluminación artificial severa, que es muy usada en estos sistemas.

2.2 Descripción del marco teórico

3 Método o Procedimiento de Investigación

3.1 Descripción del método

En este capítulo se explica y describe la metodología desarrollada para la calibración adaptativa y la restauración geométricamente consistente de cámaras subacuáticas en vehículos ROV. Está estructurado en cinco fases principales:

1. Instrumentación del banco de pruebas controlado (planta experimental)

2. Adquisición de imágenes bajo variaciones monovariables y multivariables de temperatura, componentes RGB e iluminación

3. Caracterización del impacto de dichas variables sobre la matriz intrínseca de la cámara

4. Desarrollo e integración del algoritmo adaptativo de bajo costo computacional

5. Evaluación del desempeño en tareas de medición y reconstrucción tridimensional.

3.2 Equipos, Materiales e Instrumentación

Para la ejecución de las pruebas experimentales y la recolección del conjunto de datos se emplearon los siguientes elementos e instrumentos:

- **Estanque de pruebas (pecera):** Recipiente de cristal de 1,5 m de largo, 1,0 m de ancho y 1,0 m de alto, utilizado para el control fino y monitoreo ambiental.

- **Alberca de pruebas:** Alberca de agua dulce con profundidad graduable de 1,2 m a 2,5 m, utilizado para la validación final.

- **Patrón de calibración:** Tablero planar con patrón de ajedrez (*checkerboard*) impreso en alta resolución sobre papel rígido e impermeable, compuesto por cuadrados de 25,0 mm por lado con precisión submilimétrica en la intersección de esquinas.

- **Sistema de adquisición visual:** Cámara subacuática marca *DeepWater Exploration* con sensor CMOS HD, encapsulado IP68 y puerto plano (*flat-port*) de acrílico.

- **Sistema de control y monitoreo térmico:** Acondicionado en el estanque de pruebas mediante tres resistencias eléctricas sumergibles de 1000 W distribuidas equidistantemente a 500 mm, acopladas a tres sensores de temperatura tipo termopar encapsulados en acero inoxidable colocados a 20 mm de cada elemento calefactor para retroalimentación en bucle cerrado.

- **Sistema de monitoreo cromático (RGB):** Sensor de color espectral calibrado para medir la absorbancia del fluido, acoplado a un sistema de dosificación de colorantes solubles para modificar la respuesta espectral del agua.

- **Sistema de iluminación artificial regulable:** Arreglo de tres focos LED subacuáticos de 100 W cada uno, montados sobre soportes articulados con control electrónico de intensidad PWM y posicionamiento angular.

3.3 Diseño Experimental y Clasificación de Variables

El diseño experimental contempla la manipulación de manera controlada de tres variables principales para evaluar su impacto individual y acoplado sobre la respuesta geométrica del sensor.

- **Variables Independientes:**
  - *Temperatura del fluido (T):* Variada en el rango de 15°C a 40°C, bajo dos tipos de operación: distribución uniforme y gradientes térmicos no uniformes.
  - *Atenuación por componentes RGB ($\alpha_R, \alpha_G, \alpha_B$):* Variación cuantitativa del color del agua mediante concentración de colorante por canal espectral (rojo, verde y azul).
  - *Iluminación artificial ($I_{LED}, \mathbf{p}_{LED}$):* Intensidad luminosa (0 % a 100 %) y posición espacial/ángulo respecto al eje óptico de la cámara.
- **Variables Dependientes:**
  - *Matriz de parámetros intrínsecos ($\mathbf{K}$):* Distancia focal (f_x, f_y), centro principal (c_x, c_y) y sesgo (*skew*).
  - *Coeficientes de distorsión radial y tangencial:* (k_1, k_2, p_1, p_2).
  - *Error de reproyección (e_{rep}):* Expresado en píxeles (px).
  - *Error de reconstrucción 3D (E_{3D}):* Desviación métrica en milímetros (mm) sobre geometría conocida.
- **Variables Controladas:** Distancia nominal cámara-objetivo (1,0 m), geometría fija del *housing*/puerto plano y rigidez mecánica del soporte.

3.4 Procedimiento Experimental y Procesamiento

La metodología de desarrollo se dividió en las siguientes etapas:

3.4.1 Instrumentación de la Planta Experimental

Se acondicionó la pecera de cristal integrando los subsistemas de control. Para el módulo de temperatura, se colocaron las tres resistencias junto con termopares lo cual permitió tener perfiles de temperatura homogéneos así como no homogéneos.

Para la iluminación, se colocaron de manera triaxial focos LED que permitieron simular condiciones de deslumbramiento, sombreado asimétrico y atenuación por distancia.

Para la manipulación cromática, se empleó un sistema de dosificación de colorante soluble en agua, medido con un sensor de color calibrado previamente para obtener concentraciones lineales por canal.

3.4.2 Adquisición y Análisis Monovariable

Se adquirieron conjuntos de imágenes del tablero de calibración situados a 1,0 m de distancia, capturando 10 tomas por cada orientación (mínimo 15 posiciones) y repitiéndolo para diferentes distancias bajo las siguientes condiciones aisladas:

1. **Pruebas térmicas:** Se incrementó la temperatura T de 15°C a 40°C en pasos de 5°C de forma uniforme, y posteriormente se indujo un gradiente térmico no uniforme. Para cada estado se estimó la matriz **K** mediante el algoritmo de Zhang (Z. Zhang, 2000) para cuantificar la deriva de la distancia focal $f(T)$ asociada al cambio en el índice de refracción $n(T)$.
2. **Pruebas cromáticas RGB:** Se adicionó colorante selectivo por canal (R, G y B consecutivamente) en agua a temperatura constante. Se procesaron los patrones para cuantificar la degradación de gradientes de intensidad en las esquinas del ajedrez y su efecto en la localización subpíxel.
3. **Pruebas de iluminación:** Se varió la intensidad luminosa de 0 % a 100 % y se modificó el ángulo de incidencia de los focos LED. Se analizó el impacto de sombras marcadas, saturación de píxeles y pérdida de contraste sobre el cálculo de los intrínsecos.

3.4.3 Adquisición y Análisis Multivariable

Se capturó la matriz de datos acoplada combinando simulación de operación real de ROV:

1. Combinación de temperatura T cambiante e iluminación no uniforme con tono cromático constante.

2. Combinación de temperatura T y atenuación cromática RGB variable con iluminación constante.

3. Variación simultánea de los tres factores (T, RGB e iluminación I_{LED}) para constituir la base de datos de entrenamiento y validación del algoritmo adaptativo.

3.4.4 Desarrollo del Algoritmo Adaptativo Liviano

A partir del análisis del conjunto de datos, se estructuró una arquitectura ligera dividida en dos bloques acoplados:

- **Módulo de Restauración Radiométrica/Cromática:** Restaura los gradientes de intensidad y atenúa los efectos de la iluminación no uniforme mediante un filtrado adaptativo de bajo costo computacional.

- **Módulo de Estimación Intrínseca Adaptativa:** Un modelo funcional ajusta dinámicamente los parámetros (f_x, f_y, c_x, c_y) en función de la temperatura medida T y los índices cromáticos calculados, recalculando la matriz $\mathbf{K}(T, \mathrm{RGB})$ en tiempo real sin requerir una recalibración completa con tablero.

3.4.5 Sistema de Medición y Reconstrucción Tridimensional

Se implementó un pipeline de visión estereoscópica/monocular corregida. Utilizando la matriz de intrínsecos adaptativa $\mathbf{K}(T, \mathrm{RGB})$, se proyectan los puntos característicos detectados en la imagen al espacio tridimensional mediante geometría epipolar y triangulación, corrigiendo previamente la distorsión refractiva producida por el medio dinámico.

3.4.6 Evaluación del Desempeño

El algoritmo desarrollado se evaluó comparativamente frente a la calibración estática convencional mediante tres métricas clave:

1. **Error de reproyección (e_{rep}):** Calculado como la distancia euclidiana promedio entre las esquinas detectadas y las esquinas proyectadas mediante el modelo estimado.
2. **Estabilidad temporal de parámetros:** Desviación estándar de f_x, f_y, c_x, c_y durante ciclos térmicos continuos.
3. **Error métrico 3D (E_{3D}):** Diferencia absoluta en milímetros entre la distancia real de patrones patrones de prueba sumergidos y la medida reconstruida digitalmente.

4 Resultados

4.1 Descripción de los resultados

5 Conclusiones y Recomendaciones

5.1 Conclusiones

5.2 Recomendaciones

6 Referencias

Berman, D., Levy, D., Avidan, S., & Treibitz, T. (2021). Underwater Single Image Color Restoration Using Haze-Lines and a New Quantitative Dataset. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, *43*(8), 2822-2837. https://doi.org/10.1109/TPAMI.2020.2977624

Du, D., Si, L., Xu, F., Niu, J., & Sun, F. (2026). A Physical Model-Guided Framework for Underwater Image Enhancement and Depth Estimation. *IEEE Transactions on Circuits and Systems for Video Technology*, *36*(7), 10244-10259. https://doi.org/10.1109/TCSVT.2026.3674091

Dudhane, A., Hambarde, P., Patil, P., & Murala, S. (2020). Deep Underwater Image Restoration and Beyond. *IEEE Signal Processing Letters*, *27*, 675-679. https://doi.org/10.1109/LSP.2020.2988590

Fan, J., Xu, J., Zhou, J., Meng, D., & Lin, Y. (2025). See Through Water: Heuristic Modeling Toward Color Correction for Underwater Image Enhancement. *IEEE Transactions on Circuits and Systems for Video Technology*, *35*(5), 4039-4054. https://doi.org/10.1109/TCSVT.2024.3516781

Ke, K., Zhang, C., Wang, Y., Zhang, Y., & Yao, B. (2023). Single underwater image restoration based on color correction and optimized transmission map estimation. *Measurement Science and Technology*, *34*(5), 055408. https://doi.org/10.1088/1361-6501/acb72d

Li, C., Anwar, S., & Porikli, F. (2020). Underwater scene prior inspired deep underwater image and video enhancement. *Pattern Recognition*, *98*, 107038. https://doi.org/https://doi.org/10.1016/j.patcog.2019.107038

Li, J., Skinner, K. A., Eustice, R. M., & Johnson-Roberson, M. (2018). WaterGAN: Unsupervised Generative Network to Enable Real-Time Color Correction of

Monocular Underwater Images. *IEEE Robotics and Automation Letters*, *3*(1), 387-394. https://doi.org/10.1109/LRA.2017.2730363

Lin, Y., Shen, L., Wang, Z., Wang, K., & Zhang, X. (2021). Attenuation Coefficient Guided Two-Stage Network for Underwater Image Restoration. *IEEE Signal Processing Letters*, *28*, 199-203. https://doi.org/10.1109/LSP.2020.3048619

Lu, H., Li, Y., Uemura, T., Kim, H., & Serikawa, S. (2018). Low illumination underwater light field images reconstruction using deep convolutional neural networks. *Future Generation Computer Systems*, *82*, 142-148. https://doi.org/https://doi.org/10.1016/j.future.2018.01.001

Meng, F., Yu, Y., Guo, K., Song, Z., Liang, A., He, L., & Zhang, D. (2024). Implicit calibration method for underwater stereo cameras. *Opt. Express*, *32*(16), 27875-27893. https://doi.org/10.1364/OE.527645

Sánchez-Saquín, C. H., Baldenegro-Pérez, L. A., Barriga-Rodríguez, L., Medina-Montes, M. I., Fernández, J. M. B., & Salgado-Jiménez, T. (2025). Temperature and Dye Concentration Effects on Camera Calibration in Underwater Environments. *IEEE Access*, *13*, 168592-168611. https://doi.org/10.1109/ACCESS.2025.3613461

Sánchez-Saquín, C. H., Barriga-Rodríguez, L., Baldenegro-Pérez, L. A., Ronquillo-Lomeli, G., & Rodríguez-Olivares, N. A. (2024). Novel Neural Networks for Camera Calibration in Underwater Environments. *IEEE Access*, *12*, 181767-181786. https://doi.org/10.1109/ACCESS.2024.3509452

Sánchez-Saquín, C. H., Gómez-Hernández, A., Salgado-Jiménez, T., Fernández, J. M. B., Barriga-Rodríguez, L., & Gómez-Espinosa, A. (2025). Visual Signal Recognition with ResNet50V2 for Autonomous ROV Navigation in Underwater Environments. *Automation*, *6*(4), 51. https://doi.org/10.3390/automation6040051

Sharma, P., Bisht, I., & Sur, A. (2023). Wavelength-based Attributed Deep Neural Network for Underwater Image Restoration. *ACM Trans. Multimedia Comput. Commun. Appl.*, *19*(1). https://doi.org/10.1145/3511021

Vlachos, M., & Skarlatos, D. (2024). Self-Adaptive Colour Calibration of Deep Underwater Images Using FNN and SfM-MVS-Generated Depth Maps. *Remote Sensing*, *16*(7). https://doi.org/10.3390/rs16071279

Zhang, T., & Johnson-Roberson, M. (2023). Beyond NeRF Underwater: Learning Neural Reflectance Fields for True Color Correction of Marine Imagery. *IEEE Robotics and Automation Letters*, *8*(10), 6467-6474. https://doi.org/10.1109/LRA.2023.3307287

Zhang, W., Li, X., Huang, Y., Xu, S., Tang, J., & Hu, H. (2025). Underwater image enhancement via frequency and spatial domains fusion. *Optics and Lasers in Engineering*, *186*, 108826. https://doi.org/https://doi.org/10.1016/j.optlaseng.2025.108826

Zhang, W., Li, X., Xu, S., Li, X., Yang, Y., Xu, D., Liu, T., & Hu, H. (2023). Underwater Image Restoration via Adaptive Color Correction and Contrast Enhancement Fusion. *Remote Sensing*, *15*(19). https://doi.org/10.3390/rs15194699

Zhang, Z. (2000). A flexible new technique for camera calibration. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, *22*, 1330-1334. https://doi.org/10.1109/34.888718

Zhou, J., et al. (2025). Probabilistic network-based method for underwater vision measurement. *Optical Engineering*, *64*(2), 024105. https://doi.org/10.1117/1.OE.64.2.024105

Zhou, J., Liu, Q., Jiang, Q., Ren, W., Lam, K.-M., & Zhang, W. (2023). Underwater Camera: Improving Visual Perception Via Adaptive Dark Pixel Prior and Color Correction. *International Journal of Computer Vision*, *133*(11), 8215-8233. https://doi.org/10.1007/s11263-023-01853-3

Zhou, J., Wang, Y., Li, C., & Zhang, W. (2023). Multicolor Light Attenuation Modeling for Underwater Image Restoration. *IEEE Journal of Oceanic Engineering*, *48*(4), 1322-1337. https://doi.org/10.1109/JOE.2023.3275615

Appendices

A Formato y Contenido de Tesis

Declaración de Autoría

Por la presente declaro que he elaborado este documento sin la ayuda prohibida de terceros y sin hacer uso de ayudas distintas de las especificadas; nociones asumidas directamente o indirectamente de otras fuentes se han identificado como tales. Este documento no ha sido previamente presentado en forma idéntica o similar de algún otro examen nacional o extranjero.

El trabajo de tesis se llevó a cabo de **año de inicio del trabajo** a **año de término del trabajo** bajo la supervisión del Dr.**Nombre apellidos del director de tesis**.

Santiago de Querétaro, Qro., a 2 de noviembre de 2026