

Resumen

Índice

Introducción	1
Planteamiento del problema	2
Objetivos	3
Objetivo General	3
Objetivos Específicos	3
Justificación	4
Antecedentes	5
Metodología	10
Resultados	11
Conclusiones	12
Bibliografía	13
Anexos	16

Índice de figuras

Introducción

Se propone desarrollar un algoritmo robusto de calibración de cámaras submarinas para sistemas de visión de vehículos ROV, capaz de mantener su precisión ante variaciones en las condiciones de adquisición de las imágenes. El algoritmo considerará el efecto de la temperatura del agua, variaciones en los componentes RGB e iluminación, buscando minimizar su influencia sobre los parámetros de calibración. La validación se realizará mediante experimentos controlados en tanque de agua y alberca. Se evaluará el desempeño del método mediante error de reproyección, estabilidad de los parámetros de calibración y precisión en reconstrucción 3D y medición de objetos submarinos.

Planteamiento del problema

Objetivos

Objetivo General

Objetivos Específicos

Justificación

Antecedentes

La visión subacuática tiene 2 principales desafíos, la distorsión geométrica causada por la refracción en el agua-vidrio-aire que tiene la cámara, y la degradación radiométrica, que es el color, contraste, entre otras. Esta es principalmente provocada porque el agua absorbe y dispersa la luz que recibe. Desde hace muchos años la calibración de las cámaras que se usan en entornos submarinos se realizó con modelos geométricos rígidos, que estaban centrados en la corrección por refracción, como por ejemplo el método de Zhang (Z. Zhang, 2000). Pero estos enfoques no tienen en cuenta otros factores ambientales, como la temperatura, la salinidad, la iluminación, o incluso la interacción de la luz con el medio en sí (Sánchez-Saquín, Baldenegro-Pérez et al., 2025). Con el paso de los años estos métodos de restauración y calibración han avanzado a través de modelos físicos orientados a la física del medio, y más reciente, usando inteligencia artificial y redes neuronales.

Evolución de los Modelos Físicos y Métodos Tradicionales

Entre **2005 - 2016** los primeros acercamientos fueron usando hardware óptico especializado, o de la adaptación directa de priors atmosféricos terrestres (el *Dark Channel Prior*) (W. Zhang et al., 2023) (Ke et al., 2023). Estos funcionaban en entornos controlados, pero tenían muchas limitaciones, los priors terrestres fallaban por la absorción dependiente de la longitud de onda y la arena brillante (Berman et al., 2021).

Después, entre **2017 - 2019** se empezó a introducir el modelado explícito de la atenuación espectral mediante curvas de Haze-Lines y métodos de estimación de profundidad por desenfoque y absorción (IBLA) (W. Zhang et al., 2023) (Ke et al., 2023). Esto permitió considerar la degradación por longitud de onda, tenían problemas e ineficiencias en zonas marinas sin textura (zonas donde no se puede estimar la profundidad), aparte de que tienen una calcificación muy rígida para poder ser usada en cuerpos de agua reales y cambiantes (Ke et al., 2023) (Berman et al., 2021).

Entre **2020 - 2023** se centraron más en investigar el desacoplamiento de fenómenos ópticos. Para ello se incorporó el balance cromático adaptativo en diversos espacios de color, también la estimación del *backscatter* mediante píxeles oscuros adaptativos, modelos MCLA con ley de Lambert-Beer (Zhou, Wang et al., 2023) y balance adap-

tativo en espacios *Lab* y *CIE L*a*b** (W. Zhang et al., 2023). Los resultados tuvieron mayor fidelidad en la restauración, pero tenían una corrección deficiente cuando se usaba iluminación artificial severa, que es muy usada en ROVs y AUVs, además generaba artefactos en regiones oscuras o sobrecompensación en el canal rojo.

En los años **2024 - 2025** surgieron modelos heurísticos avanzados (MJPNet) (Fan et al., 2025) y filtros homomórficos acoplados a restricciones físicas con clasificación por factor de riesgo de sesgo cromático (W. Zhang et al., 2025), la complejidad, consumo computacional, y rigidez por la dependencia de datasets de entrenamiento causó que sea complicado usarlos en entornos reales sobre todo en sistemas embebidos de AUVs y ROVs en tiempo real.

Evolución de los Modelos de Inteligencia Artificial y Redes Neuronales

Las redes neuronales inicialmente fueron empleadas para mejorar el color e imagen obtenida, poco tiempo después empezaron a calibrar las cámaras directamente, siguiendo una trayectoria de 3 fases: primero se emplearon para mejorar las imágenes degradadas, después se emplearon modelos híbridos, que estiman las variables físicas como la profundidad, la transmisión y el *backscatter*, y finalmente recientemente, las redes aplican una calibración implícita o directa.

En los años **2017 - 2020** el problema que existía para poder emplear redes neuronales, fue la falta de ground truth submarino, *WaterGAN* generó imágenes subacuáticas de manera sintética, usando pares RGB-D en aire y con ello aprendió una corrección de color monocular en 2 etapas, esta fue validada en un tanque de agua, así como en campo (J. Li et al., 2018).

En **2018-2020** redes como CNN y redes residuales aparte de corregir el color, también lo hacían para *de-scattering*, *blur* y profundidad. En imágenes con baja iluminación, una CNN usó una estimación de profundidad y corrección espectral para compensar el *scattering* y la pérdida cromática (Lu et al., 2018). La red UWCNN directamente empezó a hacer reconstrucción directa de la imagen latente, esta fue entrenada con datos sintéticos basados en un modelo básico, y distintos tipos de agua (C. Li et al., 2020).

Otra red *end-to-end* añadió el enfoque de desenfoque a la base sintética debido a que las bases anteriores solo consideraban el *scattering* y la atenuación (Dudhane et al., 2020).

Durante los años **2021 - 2023** se dejó de tratar la restauración como algo desco-

nocido, y las redes empezaron a ser diseñadas según la física por canal. *Deep WaveNet* menciona que las imágenes subacuáticas requieren tamaños de contexto distintos por canal, esto es porque la atenuación de la longitud de onda es asimétrica, además incorporo *skip connections* atentas para refinar ciertos rasgos multicontexto (Sharma et al., 2023). Él señalaba que reutilizar CNN que eran para entornos terrestres sin rediseño para entornos subacuáticos produce artefactos y color distorsionado.

Otros métodos también fueron surgiendo, como algunos que estiman la profundidad, el *backscatter*, la iluminación y coeficientes de atenuación, esto con módulos neuronales o semi neuronales. Por ejemplo tenemos el trabajo de Zhou, que emplea prior de pixel oscuro adaptativo, combinó el modelo de formación de imagen, *Channel Intensity Prior*, la eliminación de *backscatter*, y una etapa no supervisada para reducir los efectos de usar luz artificial (Zhou, Liu et al., 2023). Otro modelo usó 2 etapas para estimar el coeficiente de atenuación, esto para guiar la restauración horizontal, luego usó un bloque de atención por prior de atenuación para recalibrar los mapas RGB en la disposición vertical (Lin et al., 2021). Al mismo tiempo, un campo de reflectancia neuronal, aprendió conjuntamente el color verdadero, la atenuación y el *backscatter* desde múltiples vistas, como la iluminación *onboard* de robots, esto sin depender de pre-entrenamiento o de mapas de profundidad obtenidos previamente (T. Zhang & Johnson-Roberson, 2023).

Finalmente, durante **2024 - 2025** el restaurar la imagen ya no es lo único que se buscaba, sino que se empezó a calibrar la cámara directamente usando redes neuronales. En 2024 un marco que fue guiado por un modelo físico de 2024 entrenó subredes separadas con el propósito de estimar la profundidad, *veiling light* y coeficientes de atenuación/*scattering*, esto fue por qué trabajos anteriores fallaban porque se invertía mucho en modelos físicos demasiado idealizados, o porque estimaban mal los parámetros anteriores (Du et al., 2026).

Específicamente en la calibración geométrica, actualmente hay 2 líneas de desarrollo, la primera usa una CNN sobre unas imágenes en el tablero para estimar directamente la matriz de calibración en agua limpia, verde y azul, obteniendo mejores resultados que Zhang y Bouguet, aparte de que válido en reconstrucción 3D (Sánchez-Saquín et al., 2024). La otra línea, en cambio, propone una calibración implícita estéreo, con una red de regresión por coordenadas y diana autoiluminada, superando a métodos explícitos en medición, postura y reconstrucción 3D (Meng et al., 2024). Existe un tercer trabajo que vincula la mejora neuronal de placas de calibración con error de re-proyección y precisa de medida, esta tiene mejor desempeño que la calibración implícita basada en datos (Zhou et al., 2025).

Tabla 1: Papers y variables usadas por redes neuronales.

Año	Paper	Parte de interés	Variables tratadas
2017	WaterGAN	Síntesis GAN + corrección monocular	profundidad, color, scattering, tipo de agua (J. Li et al., 2018)
2020	UWCNN	Reconstrucción directa con prior submarino	color, scattering, absorción, tipo de agua (C. Li et al., 2020)
2021	Deep WaveNet	Receptive fields por longitud de onda	color por canal, contexto multiescala (Sharma et al., 2023)
2023	NeRF Underwater	Aprende escena y agua conjuntamente	backscatter, atenuación, iluminación, geometría (T. Zhang & Johnson-Roberson, 2023)
2023	ADP + CIP	Modelo físico + estimación no supervisada	profundidad, backscatter, luz artificial, balance azul-verde (Zhou, Liu et al., 2023)
2024	DDM + UIEConv	Estima parámetros físicos con subredes	profundidad, veiling light, atenuación/scattering (Du et al., 2026)
2024	Implicit Stereo Calibration	Calibración implícita por regresión	profundidad, refracción, aberración espacial, postura, 3D (Meng et al., 2024)
2024	FNN + SfM-MVS	Calibración cromática auto-adaptativa	color, profundidad, iluminación por estrobos (Vlachos & Skarlatos, 2024)
2025	Probabilistic Measurement Net	Mejora imagen para calibración y medición	color, contraste, nitidez, distorsión (Zhou et al., 2025)

Para la calibración de color también se volvió más geométrico. Hay un método auto-adaptativo para aguas profundas que usa mapas de profundidad generados por SfM-MVS, zonas bien iluminadas y una FNN para restaurar el color sin tener que usar cartas de color ni información del ambiente de manera precisa, esto siempre y cuando la configuración de la cámara-luz se mantenga estable (Vlachos & Skarlatos, 2024). Este sistema aunque ya está más cerca de una calibración operativa, aun sigue dependiendo de solape suficiente y de que algunas regiones funcionen como *pseudo-ground-truth* Cromático.

Metodología

Resultados

Conclusiones

Bibliografia

- Berman, D., Levy, D., Avidan, S., & Treibitz, T. (2021). Underwater Single Image Color Restoration Using Haze-Lines and a New Quantitative Dataset. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 43(8), 2822-2837. <https://doi.org/10.1109/TPAMI.2020.2977624>
- Du, D., Si, L., Xu, F., Niu, J., & Sun, F. (2026). A Physical Model-Guided Framework for Underwater Image Enhancement and Depth Estimation. *IEEE Transactions on Circuits and Systems for Video Technology*, 36(7), 10244-10259. <https://doi.org/10.1109/TCSVT.2026.3674091>
- Dudhane, A., Hambarde, P., Patil, P., & Murala, S. (2020). Deep Underwater Image Restoration and Beyond. *IEEE Signal Processing Letters*, 27, 675-679. <https://doi.org/10.1109/LSP.2020.2988590>
- Fan, J., Xu, J., Zhou, J., Meng, D., & Lin, Y. (2025). See Through Water: Heuristic Modeling Toward Color Correction for Underwater Image Enhancement. *IEEE Transactions on Circuits and Systems for Video Technology*, 35(5), 4039-4054. <https://doi.org/10.1109/TCSVT.2024.3516781>
- Ke, K., Zhang, C., Wang, Y., Zhang, Y., & Yao, B. (2023). Single underwater image restoration based on color correction and optimized transmission map estimation. *Measurement Science and Technology*, 34(5), 055408. <https://doi.org/10.1088/1361-6501/acb72d>
- Li, C., Anwar, S., & Porikli, F. (2020). Underwater scene prior inspired deep underwater image and video enhancement. *Pattern Recognition*, 98, 107038. <https://doi.org/https://doi.org/10.1016/j.patcog.2019.107038>
- Li, J., Skinner, K. A., Eustice, R. M., & Johnson-Roberson, M. (2018). WaterGAN: Unsupervised Generative Network to Enable Real-Time Color Correction of Monocular Underwater Images. *IEEE Robotics and Automation Letters*, 3(1), 387-394. <https://doi.org/10.1109/LRA.2017.2730363>
- Lin, Y., Shen, L., Wang, Z., Wang, K., & Zhang, X. (2021). Attenuation Coefficient Guided Two-Stage Network for Underwater Image Restoration. *IEEE Signal Processing Letters*, 28, 199-203. <https://doi.org/10.1109/LSP.2020.3048619>

- Lu, H., Li, Y., Uemura, T., Kim, H., & Serikawa, S. (2018). Low illumination underwater light field images reconstruction using deep convolutional neural networks. *Future Generation Computer Systems*, 82, 142-148. <https://doi.org/https://doi.org/10.1016/j.future.2018.01.001>
- Meng, F., Yu, Y., Guo, K., Song, Z., Liang, A., He, L., & Zhang, D. (2024). Implicit calibration method for underwater stereo cameras. *Opt. Express*, 32(16), 27875-27893. <https://doi.org/10.1364/OE.527645>
- Sánchez-Saquín, C. H., Baldenegro-Pérez, L. A., Barriga-Rodríguez, L., Medina-Montes, M. I., Fernández, J. M. B., & Salgado-Jiménez, T. (2025). Temperature and Dye Concentration Effects on Camera Calibration in Underwater Environments. *IEEE Access*, 13, 168592-168611. <https://doi.org/10.1109/ACCESS.2025.3613461>
- Sánchez-Saquín, C. H., Barriga-Rodríguez, L., Baldenegro-Pérez, L. A., Ronquillo-Lomeli, G., & Rodríguez-Olivares, N. A. (2024). Novel Neural Networks for Camera Calibration in Underwater Environments. *IEEE Access*, 12, 181767-181786. <https://doi.org/10.1109/ACCESS.2024.3509452>
- Sánchez-Saquín, C. H., Gómez-Hernández, A., Salgado-Jiménez, T., Fernández, J. M. B., Barriga-Rodríguez, L., & Gómez-Espinosa, A. (2025). Visual Signal Recognition with ResNet50V2 for Autonomous ROV Navigation in Underwater Environments. *Automation*, 6(4), 51. <https://doi.org/10.3390/automation6040051>
- Sharma, P., Bisht, I., & Sur, A. (2023). Wavelength-based Attributed Deep Neural Network for Underwater Image Restoration. *ACM Trans. Multimedia Comput. Commun. Appl.*, 19(1). <https://doi.org/10.1145/3511021>
- Vlachos, M., & Skarlatos, D. (2024). Self-Adaptive Colour Calibration of Deep Underwater Images Using FNN and SfM-MVS-Generated Depth Maps. *Remote Sensing*, 16(7). <https://doi.org/10.3390/rs16071279>
- Zhang, T., & Johnson-Roberson, M. (2023). Beyond NeRF Underwater: Learning Neural Reflectance Fields for True Color Correction of Marine Imagery. *IEEE Robotics and Automation Letters*, 8(10), 6467-6474. <https://doi.org/10.1109/LRA.2023.3307287>
- Zhang, W., Li, X., Huang, Y., Xu, S., Tang, J., & Hu, H. (2025). Underwater image enhancement via frequency and spatial domains fusion. *Optics and Lasers in Engineering*, 186, 108826. <https://doi.org/https://doi.org/10.1016/j.optlaseng.2025.108826>

- Zhang, W., Li, X., Xu, S., Li, X., Yang, Y., Xu, D., Liu, T., & Hu, H. (2023). Underwater Image Restoration via Adaptive Color Correction and Contrast Enhancement Fusion. *Remote Sensing*, 15(19). <https://doi.org/10.3390/rs15194699>
- Zhang, Z. (2000). A flexible new technique for camera calibration. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 22, 1330-1334. <https://doi.org/10.1109/34.888718>
- Zhou, J., et al. (2025). Probabilistic network-based method for underwater vision measurement. *Optical Engineering*, 64(2), 024105. <https://doi.org/10.1117/1.OE.64.2.024105>
- Zhou, J., Liu, Q., Jiang, Q., Ren, W., Lam, K.-M., & Zhang, W. (2023). Underwater Camera: Improving Visual Perception Via Adaptive Dark Pixel Prior and Color Correction. *International Journal of Computer Vision*, 133(11), 8215-8233. <https://doi.org/10.1007/s11263-023-01853-3>
- Zhou, J., Wang, Y., Li, C., & Zhang, W. (2023). Multicolor Light Attenuation Modeling for Underwater Image Restoration. *IEEE Journal of Oceanic Engineering*, 48(4), 1322-1337. <https://doi.org/10.1109/JOE.2023.3275615>

Anexos