

Resumen

Índice

Introducción	1
Planteamiento del problema	2
Objetivos	3
Objetivo General	3
Objetivos Específicos	3
Justificación	4
Antecedentes	5
Metodología	10
Resultados	11
Conclusiones	12
Bibliografía	13

Índice de figuras

Introducción

Se propone desarrollar un algoritmo robusto de calibración de cámaras submarinas para sistemas de visión de vehículos ROV, capaz de mantener su precisión ante variaciones en las condiciones de adquisición de las imágenes. El algoritmo considerará el efecto de la temperatura del agua, variaciones en los componentes RGB e iluminación, buscando minimizar su influencia sobre los parámetros de calibración. La validación se realizará mediante experimentos controlados en tanque de agua y alberca. Se evaluará el desempeño del método mediante error de reproyección, estabilidad de los parámetros de calibración y precisión en reconstrucción 3D y medición de objetos submarinos.

Planteamiento del problema

Objetivos

Objetivo General

Objetivos Específicos

Justificación

Antecedentes

Para la calibración de cámaras subacuáticas, es necesario modelar la refracción en agua-vidrio-aire, la distorsión de la imagen por el lente, factores ambientales como temperatura, salinidad, color, iluminación. En general la mayoría de los métodos actuales se centran en la corrección geométrica por refracción como la calibración de Zhang (Z. Zhang, 2000), a diferencia de la integración de efectos térmicos y de color (Sánchez-Saquín, Baldenegro-Pérez et al., 2025).

2005 - 2016:

Se usa hardware óptico y adaptación directa de priors atmosféricos terrestres.

Tiene problemas por absorción de los canales de color.

2017 - 2019:

Modelado de la atenuación de la luz según la longitud de onda y curvas de Haze-lines,

Se emplearon la estimación de profundidad por desenfoque y absorción (IBLA)

Hay una ineficiencia severa en regiones sin textura (en zonas donde no se puede estimar la profundidad), y hay una clasificación demasiado rígida para ser usada en cuerpos de agua reales y cambiantes.

2020 - 2023:

Desacoplamiento de fenómenos, balance cromático adaptativo, pérdida de color. Se usa la estimación de *backscatter* mediante píxeles oscuros adaptativos. Modelos MCLA sustentados en la Ley de Lambert-Beer. El balance de color adaptativo en espacios cromáticos.

Hay una corrección deficiente ante iluminación artificial severa, muy usada en ROVs y

AUVs, además de generación de artefactos en regiones oscuras o sobre-compensados en el canal rojo.

2024 - 2025:

Usa redes neuronales profundas, con restricciones físicas al medio acuático, emplean clasificación por factor de riesgo de sesgo cromático y filtrado homomórfico. Transformers con priors integrados para el balance de color. Modelos heurísticos avanzados.

Tiene un gran coste computacional, lo cual hace más compleja o impide totalmente su uso en tiempo real en sistemas embebidos en ROVs y AUVs, además de que depende mucho del dataset del entrenamiento.

Las redes neuronales inicialmente fueron empleadas para mejorar el color e imagen obtenida, poco tiempo después empezaron a calibrar las cámaras directamente, siguiendo una trayectoria de 3 fases: primero se emplearon para mejorar las imágenes degradadas, después se emplearon modelos híbridos, que estiman las variables físicas como la profundidad, la transmisión y el backscatter, y finalmente recientemente, las redes aplican una calibración implícita o directa.

2017 - 2020:

El problema que existía para poder emplear redes neuronales, fue la falta de ground truth submarino, *WaterGAN* generó imágenes subacuáticas de manera sintética, usando pares RGB-D en aire y con ello aprendió una corrección de color monocular en 2 etapas, esta fue validada en un tanque de agua, así como en campo (J. Li et al., 2018).

En **2018-2020**, redes como CNN y redes residuales aparte de corregir el color, también lo hacían para *de-scattering*, *blur* y profundidad. En imágenes con baja iluminación, una CNN usó una estimación de profundidad y corrección espectral para compensar el *scattering* y la pérdida cromática (Lu et al., 2018). La red UWCNN directamente empezó a hacer reconstrucción directa de la imagen latente, esta fue entrenada con datos sintéticos basados en un modelo básico, y distintos tipos de agua (C. Li et al., 2020).

Otra red *end-to-end* añadió el enfoque de desenfoque a la base sintética debido a que la

bases anteriores solo consideraban el *scattering* y la atenuación (Dudhane et al., 2020).

2021 - 2023:

En estos años se dejó de tratar la restauración como algo desconocido, y las redes empezó a ser diseñadas según la física por canal. *Deep WaveNet* menciona que las imágenes subacuáticas requieren tamaños de contexto distintos por canal, esto es porque la atenuación de la longitud de onda es asimétrica, además incorporo *skip connections* atentas para refinar ciertos rasgos multicontexto (Sharma et al., 2023). Él señalaba que reutilizar CNN que eran para entornos terrestres sin rediseño para entornos subacuáticos produce artefactos y color distorsionado.

Otros métodos también fueron surgiendo, como algunos que estiman la profundidad, el *backscatter*, la iluminación y coeficientes de atenuación, esto con módulos neuronales o semi neuronales. Por ejemplo tenemos el trabajo de Zhou, que empleo prior de pixel oscuro adaptativo, combinó el modelo de formación de imagen, *Channel Intensity Prior*, la eliminación de *backscatter*, y una etapa no supervisada para reducir los efectos de usar luz artificial (Zhou et al., 2023). Otro modelo uso 2 etapas para estimar el coeficiente de atenuación, esto para guiar la restauración horizontal, luego usó un bloque de atención por prior de atenuación para recalibrar los mapas RGB en la disposición vertical (Lin et al., 2021). Al mismo tiempo, un campo de reflectancia neuronal, aprendió conjuntamente el color verdadero, la atenuación y el *backscatter* desde múltiples vistas, como la iluminación *onboard* de robots, esto sin depender de pre-entrenamiento o de mapas de profundidad obtenidos previamente (T. Zhang & Johnson-Roberson, 2023).

2024 - 2025:

En estos años el restaurar la imagen ya no es lo único que se buscaba, sino que se empezó a calibrar la cámara directamente usando redes neuronales. En 2024 un marco que fue guiado por un modelo físico de 2024 entrenó subredes separadas con el propósito de estimar la profundidad, *veiling light* y coeficientes de atenuación/*scattering*, esto fue por qué trabajos anteriores fallaban porque se invertía mucho en modelos físicos demasiado idealizados, o porque estimaban mal los parámetros anteriores (Du et al., 2026).

Específicamente en la calibración geométrica, actualmente hay 2 líneas de desarrollo, la primera usa una CNN sobre unas imágenes en el tablero para estimar directamente la

Tabla 1: Papers y variables usadas por redes neuronales.

Año	Paper	Parte de interés	Variables tratadas
2017	WaterGAN	Síntesis GAN + corrección monocular	profundidad, color, scattering, tipo de agua (J. Li et al., 2018)
2020	UWCNN	Reconstrucción directa con prior submarino	color, scattering, absorción, tipo de agua (C. Li et al., 2020)
2021	Deep WaveNet	Receptive fields por longitud de onda	color por canal, contexto multiescala (Sharma et al., 2023)
2023	NeRF Underwater	Aprende escena y agua conjuntamente	backscatter, atenuación, iluminación, geometría (T. Zhang & Johnson-Roberson, 2023)
2023	ADP + CIP	Modelo físico + estimación no supervisada	profundidad, backscatter, luz artificial, balance azul-verde (Zhou et al., 2023)
2024	DDM + UIEConv	Estima parámetros físicos con subredes	profundidad, veiling light, atenuación/scattering (Du et al., 2026)
2024	Implicit Stereo Calibration	Calibración implícita por regresión	profundidad, refracción, aberración espacial, postura, 3D (Meng et al., 2024)
2024	FNN + SfM-MVS	Calibración cromática auto-adaptativa	color, profundidad, iluminación por estrobos (Vlachos & Skarlatos, 2024)
2025	Probabilistic Measurement Net	Mejora imagen para calibración y medición	color, contraste, nitidez, distorsión (Zhou et al., 2025)

matriz de calibración en agua limpia, verde y azul, obteniendo mejores resultados que Zhang y Bouguet, aparte de que valido en reconstrucción 3D (Sánchez-Saquín et al., 2024). La otra línea, en cambio, propone una calibración implícita estéreo, con una red de regresión por coordenadas y diana autoiluminada, superando a métodos explícitos en medición, postura y reconstrucción 3D (Meng et al., 2024). Existe un tercer trabajo que vincula la mejora neuronal de placas de calibración con error de re-proyección y precisa de medida, esta tiene mejor desempeño que la calibración implícita basada en datos (Zhou et al., 2025).

Para la calibración de color también se volvió más geométrico. Hay un método auto-adaptativo para aguas profundas que usa mapas de profundidad generados por SfM-MVS, zonas bien iluminadas y una FNN para restaurar el color sin tener que usar cartas de color ni información del ambiente de manera precisa, esto siempre y cuando la configuración de la cámara-luz se mantenga estable (Vlachos & Skarlatos, 2024). Este sistema aunque ya está más cerca de una calibración operativa, aun sigue dependiendo de solape suficiente y de que algunas regiones funcionen como *pseudo-ground-truth* Cromático.

Metodología

Resultados

Conclusiones

Bibliografía

- Du, D., Si, L., Xu, F., Niu, J., & Sun, F. (2026). A Physical Model-Guided Framework for Underwater Image Enhancement and Depth Estimation. *IEEE Transactions on Circuits and Systems for Video Technology*, 36(7), 10244-10259. <https://doi.org/10.1109/TCSVT.2026.3674091>
- Dudhane, A., Hambarde, P., Patil, P., & Murala, S. (2020). Deep Underwater Image Restoration and Beyond. *IEEE Signal Processing Letters*, 27, 675-679. <https://doi.org/10.1109/LSP.2020.2988590>
- Li, C., Anwar, S., & Porikli, F. (2020). Underwater scene prior inspired deep underwater image and video enhancement. *Pattern Recognition*, 98, 107038. <https://doi.org/https://doi.org/10.1016/j.patcog.2019.107038>
- Li, J., Skinner, K. A., Eustice, R. M., & Johnson-Roberson, M. (2018). WaterGAN: Unsupervised Generative Network to Enable Real-Time Color Correction of Monocular Underwater Images. *IEEE Robotics and Automation Letters*, 3(1), 387-394. <https://doi.org/10.1109/LRA.2017.2730363>
- Lin, Y., Shen, L., Wang, Z., Wang, K., & Zhang, X. (2021). Attenuation Coefficient Guided Two-Stage Network for Underwater Image Restoration. *IEEE Signal Processing Letters*, 28, 199-203. <https://doi.org/10.1109/LSP.2020.3048619>
- Lu, H., Li, Y., Uemura, T., Kim, H., & Serikawa, S. (2018). Low illumination underwater light field images reconstruction using deep convolutional neural networks. *Future Generation Computer Systems*, 82, 142-148. <https://doi.org/https://doi.org/10.1016/j.future.2018.01.001>
- Meng, F., Yu, Y., Guo, K., Song, Z., Liang, A., He, L., & Zhang, D. (2024). Implicit calibration method for underwater stereo cameras. *Opt. Express*, 32(16), 27875-27893. <https://doi.org/10.1364/OE.527645>
- Sánchez-Saquín, C. H., Baldenegro-Pérez, L. A., Barriga-Rodríguez, L., Medina-Montes, M. I., Fernández, J. M. B., & Salgado-Jiménez, T. (2025). Temperature and Dye Concentration Effects on Camera Calibration in Underwater Environments.

- IEEE Access*, 13, 168592-168611. <https://doi.org/10.1109/ACCESS.2025.3613461>
- Sánchez-Saquín, C. H., Barriga-Rodríguez, L., Baldenegro-Pérez, L. A., Ronquillo-Lomeli, G., & Rodríguez-Olivares, N. A. (2024). Novel Neural Networks for Camera Calibration in Underwater Environments. *IEEE Access*, 12, 181767-181786. <https://doi.org/10.1109/ACCESS.2024.3509452>
- Sánchez-Saquín, C. H., Gómez-Hernández, A., Salgado-Jiménez, T., Fernández, J. M. B., Barriga-Rodríguez, L., & Gómez-Espinosa, A. (2025). Visual Signal Recognition with ResNet50V2 for Autonomous ROV Navigation in Underwater Environments. *Automation*, 6(4), 51. <https://doi.org/10.3390/automation6040051>
- Sharma, P., Bisht, I., & Sur, A. (2023). Wavelength-based Attributed Deep Neural Network for Underwater Image Restoration. *ACM Trans. Multimedia Comput. Commun. Appl.*, 19(1). <https://doi.org/10.1145/3511021>
- Vlachos, M., & Skarlatos, D. (2024). Self-Adaptive Colour Calibration of Deep Underwater Images Using FNN and SfM-MVS-Generated Depth Maps. *Remote Sensing*, 16(7). <https://doi.org/10.3390/rs16071279>
- Zhang, T., & Johnson-Roberson, M. (2023). Beyond NeRF Underwater: Learning Neural Reflectance Fields for True Color Correction of Marine Imagery. *IEEE Robotics and Automation Letters*, 8(10), 6467-6474. <https://doi.org/10.1109/LRA.2023.3307287>
- Zhang, Z. (2000). A flexible new technique for camera calibration. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 22, 1330-1334. <https://doi.org/10.1109/34.888718>
- Zhou, J., et al. (2025). Probabilistic network-based method for underwater vision measurement. *Optical Engineering*, 64(2), 024105. <https://doi.org/10.1117/1.OE.64.2.024105>
- Zhou, J., Liu, Q., Jiang, Q., Ren, W., Lam, K.-M., & Zhang, W. (2023). Underwater Camera: Improving Visual Perception Via Adaptive Dark Pixel Prior and Color Correction. *International Journal of Computer Vision*, 133(11), 8215-8233. <https://doi.org/10.1007/s11263-023-01853-3>

Anexos