

CIDESI

POSGRADO INTERINSTITUCIONAL EN
CIENCIA Y TECNOLOGÍA

RESTAURACIÓN GEOMÉTRICAMENTE CONSISTENTE Y CALIBRACIÓN ADAPTATIVA DE CÁMARAS SUBMARINAS

TESIS

QUE PARA OBTENER EL GRADO ACADÉMICO DE:
MAESTRO EN CIENCIA Y TECNOLOGÍA EN
MECATRÓNICA

Presenta:

Gabriel Rodríguez Feregrino

Director de Tesis: Dr. Tomas Salgado Jiménez

Codirector / Asesor: M. en C. Cristian Hamilton Sánchez Saquín

Santiago de Querétaro, Qro., México, Octubre 2026

Resumen

El resumen es una síntesis del trabajo final que hace hincapié en sus puntos sobresalientes. Toda la información que contiene la tesis debe estar comprendida en el resumen. El objetivo de incluirse es evitar que el lector tenga que leer todo el trabajo. Sin estos resúmenes, sería difícil para los profesionales mantenerse al día en su área. Por otra parte, este resumen puede lograr que el lector se motive a leer el informe completo. En cuanto a la redacción del resumen, este puede estar escrito en tiempo pasado, ya que es la historia del trabajo terminado, o en tiempo presente, ya que constituye la aportación global al área específica. Debe cuidar cada palabra que escriba. Es una síntesis de la tesis que destaca los puntos sobresalientes, donde no se incluye ninguna interpretación de la misma. La mejor manera de redactar un resumen es pensar en una llamada de larga distancia en la que usted relata a un amigo en que consiste su trabajo. El resumen debe contener entre 250 y 500 palabras, ocupando una sola página. Recuerde que debe ser breve. El resumen debe de incluir los siguientes puntos: La descripción del problema de una forma muy breve (pueden ser 2 proposiciones: una proposición antecedente y una proposición concluyente); una breve descripción de la solución; los objetivos y de una forma muy breve los resultados obtenidos.

Palabras clave: Calibración submarina, visión por computadora, sistemas embebidos, variación térmica, restauración espectral.

Abstract

The summary synthesizes the final work that emphasizes its salient points. All the information contained in the thesis must be included in the abstract. The purpose of inclusion is to avoid the reader having to read the entire work. Without these summaries, it would be difficult for professionals to keep up-to-date in their area. On the other hand, this summary can motivate the reader to read the full report. Regarding the writing of the summary, it can be written in the past tense, since it is the history of the completed work, or in the present tense since it constitutes the global contribution to the specific area. You must take care of every word you write. It is a thesis synthesis that highlights the salient points, where no interpretation of it is included. An excellent way to write a summary is to think of a long-distance call in which you tell a friend what your job consists of. The abstract must contain between 250 and 500 words, occupying a single page. Remember to keep it brief. The abstract must include the following points: A very brief description of the problem (there can be 2 propositions: an antecedent proposition and a conclusive proposition); a brief description of the solution; the objectives and in a very brief way the results obtained.

Keywords: Underwater calibration, computer vision, embedded systems, thermal variation, spectral restoration.

Agradecimientos

Índice general

Resumen	I
Abstract	III
Glosario	XV
1. Introducción	3
1.1. Antecedentes	4
1.2. Definición del problema	4
1.3. Justificación	4
1.4. Objetivos	4
1.4.1. Objetivo General	4
1.4.2. Objetivos Específicos	4
1.4.3. Objetivos particulares	4
1.5. Hipótesis	4
2. Estado del Arte y Marco Teórico	5
2.1. Análisis del estado del arte	5
2.2. Descripción del marco teórico	10
3. Método o Procedimiento de Investigación	11
3.1. Descripción del método	11
4. Resultados	13
4.1. Descripción de los resultados	13

5. Conclusiones y Recomendaciones	15
5.1. Conclusiones	15
5.2. Recomendaciones	15
6. Referencias	17
Appendices	21
Apéndice A. Formato y Contenido de Tesis	23
Declaración de Autoría	25

Índice de figuras

Índice de tablas

2.1. Papers y variables usadas por redes neuronales.	9
--	---

Índice de listados

Glosario

El glosario es un catálogo de palabras como un antecedente a sus definiciones a lo largo del texto, pero también como una forma fácil de revisar de una forma rápida sus definiciones.

AUV Autonomous Underwater Vehicle (Vehículo Submarino Autónomo).

CIP Channel Intensity Prior.

DCP Dark Channel Prior.

IA Inteligencia Artificial.

ROV Remotely Operated Vehicle (Vehículo Operado Remotamente).

1 Introducción

Se propone desarrollar un algoritmo robusto de calibración de cámaras submarinas para sistemas de visión de vehículos ROV, capaz de mantener su precisión ante variaciones en las condiciones de adquisición de las imágenes. El algoritmo considerará el efecto de la temperatura del agua, variaciones en los componentes RGB e iluminación, buscando minimizar su influencia sobre los parámetros de calibración. La validación se realizará mediante experimentos controlados en tanque de agua y alberca. Se evaluará el desempeño del método mediante error de reproyección, estabilidad de los parámetros de calibración y precisión en reconstrucción 3D y medición de objetos submarinos.

1.1 Antecedentes

1.2 Definición del problema

1.3 Justificación

1.4 Objetivos

1.4.1 Objetivo General

1.4.2 Objetivos Específicos

1.4.3 Objetivos particulares

1.5 Hipótesis

2 Estado del Arte y Marco Teórico

2.1 Análisis del estado del arte

La visión subacuática tiene 2 principales desafíos, la distorsión geométrica causada por la refracción en el agua-vidrio-aire que tiene la cámara, y la degradación radiométrica (pérdida de contraste, atenuación cromática y dispersión), principalmente provocada porque el agua absorbe y dispersa la luz que recibe. Desde hace muchos años la calibración de las cámaras que se usan en entornos submarinos se realizó con modelos geométricos rígidos, que estaban centrados en la corrección por refracción, siendo el método de Zhang (Z. Zhang, 2000) el más representativo. Pero estos enfoques no toman en cuenta otros factores ambientales, como la temperatura, la salinidad, la iluminación, o incluso la interacción de la luz con el medio en sí (Sánchez-Saquín, Baldenegro-Pérez et al., 2025). Con el paso de los años estos métodos de restauración y calibración han avanzado a través de modelos físicos orientados a la física del medio, y más reciente, usando inteligencia artificial y redes neuronales.

Evolución de los Modelos Físicos y Métodos Tradicionales

Durante el periodo **2005 - 2016**, los primeros acercamientos fueron usando hardware óptico especializado, o de la adaptación directa de priors atmosféricos terrestres (el *Dark Channel Prior*) (W. Zhang et al., 2023) (Ke et al., 2023). Estos métodos funcionaban en entornos controlados, pero tenían muchas limitaciones, los priors terrestres fallaban por la absorción dependiente de la longitud de onda y la arena brillante (Berman et al., 2021).

Posteriormente, entre **2017 y 2019** se priorizó la investigación en el modelado explícito de la atenuación espectral mediante curvas de Haze-Lines y métodos de estimación de profundidad por desenfoque y absorción (IBLA) (W. Zhang et al., 2023) (Ke et al., 2023). Esto permitió considerar la degradación por longitud de onda, tenían problemas e ineficiencias en zonas marinas sin textura (zonas donde no se puede estimar la profundidad), aparte de que tienen una calcificación muy rígida para poder ser usada en cuerpos de agua reales y cambiantes (Ke et al., 2023) (Berman et al., 2021).

Entre **2020 y 2023** se centraron más en investigar el desacoplamiento de fenómenos ópticos. Para ello se incorporó el balance cromático adaptativo en diversos espacios de color, también la estimación del *backscatter* mediante píxeles oscuros adaptativos, modelos MCLA con ley de Lambert-Beer (Zhou, Wang et al., 2023) y balance adaptativo en espacios *Lab* y *CIE L*a*b** (W. Zhang et al., 2023). Los resultados tuvieron mayor fidelidad en la restauración, pero tenían una corrección deficiente cuando se usaba iluminación artificial severa, que es muy usada en ROVs y AUVs, además de generar artefactos en regiones oscuras o sobrecompensación en el canal rojo.

Recientemente en los años **2024 y 2025** surgieron modelos heurísticos avanzados como (MJPNet) (Fan et al., 2025) y filtros homomórficos acoplados a restricciones físicas con clasificación por factor de riesgo de sesgo cromático (W. Zhang et al., 2025). Sin embargo, la complejidad, el consumo computacional, y la rigidez debido a la dependencia de datasets de entrenamiento causó que sea complicado usarlos en entornos reales sobre todo en sistemas embebidos de AUVs y ROVs en tiempo real.

Evolución de los Modelos de Inteligencia Artificial y Redes Neuronales

La integración de redes neuronales en la visión subacuática ha seguido una línea histórica de investigación de tres fases claras: una primera etapa enfocada en la mejora de calidad de imágenes degradadas; una segunda dedicada a crear modelos híbridos que estiman variables físicas intermedias (profundidad, transmisión y *backscatter*); y una tercera etapa reciente donde las redes ejecutan calibraciones implícitas o directas sobre el sistema óptico.

En la primera fase, en los años **2017 - 2020** el principal problema para el entrenamiento de redes neuronales, fue la escasez de datos (*ground truth*) en entornos submarinos, Para ello *WaterGAN* generó imágenes subacuáticas de manera sintética, usando pares RGB-D en aire y con ello aprendió una corrección de color monocular en 2 etapas, esta fue validada en un tanque de agua, así como en campo (J. Li et al., 2018).

Entre **2018 y 2020** redes como CNN y redes residuales aparte de corregir el color, también lo hacían para *de-scattering*, *blur* y profundidad. En imágenes con baja iluminación, las redes CNN usaron una estimación de profundidad y corrección espectral para compensar el *scattering* y la pérdida cromática (Lu et al., 2018). Mientras otras redes como *UWCNN* directamente empezó a hacer reconstrucción directa de la imagen latente, esta fue entrenada con datos sintéticos basados en un modelo básico, y distintos tipos de agua (C. Li et al., 2020).

Al mismo tiempo, un marco *end-to-end* añadió el enfoque de desenfoque a la base sintética debido a que la bases anteriores solo consideraban el *scattering* y la atenuación (Dudhane et al., 2020).

Durante los años **2021 - 2023** se dejó de tratar la restauración como algo desconocido, y las redes empezó a ser diseñadas según la física por canal. Redes como *Deep WaveNet* demostraron que las imágenes subacuáticas requieren tamaños de contexto distintos por canal, esto es porque la atenuación de la longitud de onda es asimétrica, además incorporo *skip connections atentas* para refinar ciertos rasgos multicontexto (Sharma et al., 2023). Él señalaba que reutilizar CNN que eran para entornos terrestres sin rediseño para entornos subacuáticos produce artefactos y color distorsionado.

Otros métodos también fueron surgiendo, como algunos que estiman la profundidad, el *backscatter*, la iluminación y coeficientes de atenuación, esto con módulos

neuronales o semi neuronales. Por ejemplo tenemos el trabajo de Zhou, que empleo prior de pixel oscuro adaptativo, combinó el modelo de formación de imagen, *Channel Intensity Prior*, la eliminación de *backscatter*, y una etapa no supervisada para reducir los efectos de usar luz artificial (Zhou, Liu et al., 2023). Otro modelo uso 2 etapas para estimar el coeficiente de atenuación, esto para guiar la restauración horizontal, luego usó un bloque de atención por prior de atenuación para recalibrar los mapas RGB en la disposición vertical (Lin et al., 2021). Al mismo tiempo, un campo de reflectancia neuronal, aprendió conjuntamente el color verdadero, la atenuación y el *backscatter* desde múltiples vistas, como la iluminación *onboard* de robots, esto sin depender de pre-entrenamiento o de mapas de profundidad obtenidos previamente (T. Zhang & Johnson-Roberson, 2023).

Finalmente, durante **2024 - 2025** el restaurar la imagen ya no es lo único que se buscaba, sino que se empezó a calibrar la cámara directamente usando redes neuronales. En 2024 un marco que fue guiado por un modelo físico de 2024 entrenó subredes separadas con el propósito de estimar la profundidad, *veiling light* y coeficientes de atenuación/*scattering*, esto fue por qué trabajos anteriores fallaban porque se invertía mucho en modelos físicos demasiado idealizados, o porque estimaban mal los parámetros anteriores (Du et al., 2026).

Específicamente en la calibración geométrica, actualmente hay 2 líneas de desarrollo, la primera usa una CNN sobre unas imágenes en el tablero para estimar directamente la matriz de calibración en agua limpia, verde y azul, obteniendo mejores resultados que Zhang y Bouguet, aparte de que valido en reconstrucción 3D (Sánchez-Saquín et al., 2024). La otra línea, en cambio, propone una calibración implícita estéreo, con una red de regresión por coordenadas y diana autoiluminada, superando a métodos explícitos en medición, postura y reconstrucción 3D (Meng et al., 2024). Existe un tercer trabajo que vincula la mejora neuronal de placas de calibración con error de re-proyección y precisa de medida, esta tiene mejor desempeño que la calibración implícita basada en datos (Zhou et al., 2025).

Para la calibración de color también se volvió más geométrico. Hay un método auto-adaptativo para aguas profundas que usa mapas de profundidad generados por SfM-MVS, zonas bien iluminadas y una FNN para restaurar el color sin tener que usar cartas de color ni información del ambiente de manera precisa, esto siempre y cuando la configuración de la cámara-luz se mantenga estable (Vlachos & Skarlatos, 2024). Este sistema aunque ya está más cerca de una calibración operativa, aun sigue dependiendo de solape suficiente y de que algunas regiones funcionen como *pseudo-ground-truth* Cromático.

Tabla 2.1: Papers y variables usadas por redes neuronales.

Año	Paper	Parte de interés	Variables tratadas
2017	WaterGAN	Síntesis GAN + corrección monocular	profundidad, color, scattering, tipo de agua (J. Li et al., 2018)
2020	UWCNN	Reconstrucción directa con prior submarino	color, scattering, absorción, tipo de agua (C. Li et al., 2020)
2021	Deep WaveNet	Receptive fields por longitud de onda	color por canal, contexto multiescala (Sharma et al., 2023)
2023	NeRF Underwater	Aprende escena y agua conjuntamente	backscatter, atenuación, iluminación, geometría (T. Zhang & Johnson-Roberson, 2023)
2023	ADP + CIP	Modelo físico + estimación no supervisada	profundidad, backscatter, luz artificial, balance azul-verde (Zhou, Liu et al., 2023)
2024	DDM + UIEConv	Estima parámetros físicos con subredes	profundidad, veiling light, atenuación/scattering (Du et al., 2026)
2024	Implicit Stereo Calibration	Calibración implícita por regresión	profundidad, refracción, aberración espacial, postura, 3D (Meng et al., 2024)
2024	FNN + SfM-MVS	Calibración cromática auto-adaptativa	color, profundidad, iluminación por estrobos (Vlachos & Skarlatos, 2024)
2025	Probabilistic Measurement Net	Mejora imagen para calibración y medición	color, contraste, nitidez, distorsión (Zhou et al., 2025)

A pesar de los avances documentados, esta revisión del estado de arte revela que aún hay limitaciones no resueltas hasta la fecha:

- En la literatura se vio que la mayoría de métodos contemplan la profundidad, la atenuación espectral, el *backscatter* y la dispersión, ningún modelo actual tanto físico o neuronal, contempla la temperatura del agua como parámetro dinámico, esto ignora que la variación de temperatura varían directamente el índice de refracción del agua y, por lo tanto, también la respuesta óptica.
- Los métodos de calibración y restauración actuales con mayor precisión cromática y geométrica, dependen de tener una alta carga computacional, lo que imposibilita su uso en tiempo real en sistemas embebidos de ROVs y AUVs. Además de que fallan en presencia de iluminación artificial severa, que es muy usada en estos sistemas.

2.2 Descripción del marco teórico

3 Método o Procedimiento de Investigación

3.1 Descripción del método

4 Resultados

4.1 Descripción de los resultados

5 Conclusiones y Recomendaciones

5.1 Conclusiones

5.2 Recomendaciones

6 Referencias

- Berman, D., Levy, D., Avidan, S., & Treibitz, T. (2021). Underwater Single Image Color Restoration Using Haze-Lines and a New Quantitative Dataset. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 43(8), 2822-2837. <https://doi.org/10.1109/TPAMI.2020.2977624>
- Du, D., Si, L., Xu, F., Niu, J., & Sun, F. (2026). A Physical Model-Guided Framework for Underwater Image Enhancement and Depth Estimation. *IEEE Transactions on Circuits and Systems for Video Technology*, 36(7), 10244-10259. <https://doi.org/10.1109/TCSVT.2026.3674091>
- Dudhane, A., Hambarde, P., Patil, P., & Murala, S. (2020). Deep Underwater Image Restoration and Beyond. *IEEE Signal Processing Letters*, 27, 675-679. <https://doi.org/10.1109/LSP.2020.2988590>
- Fan, J., Xu, J., Zhou, J., Meng, D., & Lin, Y. (2025). See Through Water: Heuristic Modeling Toward Color Correction for Underwater Image Enhancement. *IEEE Transactions on Circuits and Systems for Video Technology*, 35(5), 4039-4054. <https://doi.org/10.1109/TCSVT.2024.3516781>
- Ke, K., Zhang, C., Wang, Y., Zhang, Y., & Yao, B. (2023). Single underwater image restoration based on color correction and optimized transmission map estimation. *Measurement Science and Technology*, 34(5), 055408. <https://doi.org/10.1088/1361-6501/acb72d>
- Li, C., Anwar, S., & Porikli, F. (2020). Underwater scene prior inspired deep underwater image and video enhancement. *Pattern Recognition*, 98, 107038. <https://doi.org/10.1016/j.patcog.2019.107038>
- Li, J., Skinner, K. A., Eustice, R. M., & Johnson-Roberson, M. (2018). WaterGAN: Unsupervised Generative Network to Enable Real-Time Color Correction of

- Monocular Underwater Images. *IEEE Robotics and Automation Letters*, 3(1), 387-394. <https://doi.org/10.1109/LRA.2017.2730363>
- Lin, Y., Shen, L., Wang, Z., Wang, K., & Zhang, X. (2021). Attenuation Coefficient Guided Two-Stage Network for Underwater Image Restoration. *IEEE Signal Processing Letters*, 28, 199-203. <https://doi.org/10.1109/LSP.2020.3048619>
- Lu, H., Li, Y., Uemura, T., Kim, H., & Serikawa, S. (2018). Low illumination underwater light field images reconstruction using deep convolutional neural networks. *Future Generation Computer Systems*, 82, 142-148. <https://doi.org/https://doi.org/10.1016/j.future.2018.01.001>
- Meng, F., Yu, Y., Guo, K., Song, Z., Liang, A., He, L., & Zhang, D. (2024). Implicit calibration method for underwater stereo cameras. *Opt. Express*, 32(16), 27875-27893. <https://doi.org/10.1364/OE.527645>
- Sánchez-Saquín, C. H., Baldenegro-Pérez, L. A., Barriga-Rodríguez, L., Medina-Montes, M. I., Fernández, J. M. B., & Salgado-Jiménez, T. (2025). Temperature and Dye Concentration Effects on Camera Calibration in Underwater Environments. *IEEE Access*, 13, 168592-168611. <https://doi.org/10.1109/ACCESS.2025.3613461>
- Sánchez-Saquín, C. H., Barriga-Rodríguez, L., Baldenegro-Pérez, L. A., Ronquillo-Lomeli, G., & Rodríguez-Olivares, N. A. (2024). Novel Neural Networks for Camera Calibration in Underwater Environments. *IEEE Access*, 12, 181767-181786. <https://doi.org/10.1109/ACCESS.2024.3509452>
- Sánchez-Saquín, C. H., Gómez-Hernández, A., Salgado-Jiménez, T., Fernández, J. M. B., Barriga-Rodríguez, L., & Gómez-Espinosa, A. (2025). Visual Signal Recognition with ResNet50V2 for Autonomous ROV Navigation in Underwater Environments. *Automation*, 6(4), 51. <https://doi.org/10.3390/automation6040051>
- Sharma, P., Bisht, I., & Sur, A. (2023). Wavelength-based Attributed Deep Neural Network for Underwater Image Restoration. *ACM Trans. Multimedia Comput. Commun. Appl.*, 19(1). <https://doi.org/10.1145/3511021>
- Vlachos, M., & Skarlatos, D. (2024). Self-Adaptive Colour Calibration of Deep Underwater Images Using FNN and SfM-MVS-Generated Depth Maps. *Remote Sensing*, 16(7). <https://doi.org/10.3390/rs16071279>
- Zhang, T., & Johnson-Roberson, M. (2023). Beyond NeRF Underwater: Learning Neural Reflectance Fields for True Color Correction of Marine Imagery. *IEEE Robotics and Automation Letters*, 8(10), 6467-6474. <https://doi.org/10.1109/LRA.2023.3307287>

- Zhang, W., Li, X., Huang, Y., Xu, S., Tang, J., & Hu, H. (2025). Underwater image enhancement via frequency and spatial domains fusion. *Optics and Lasers in Engineering*, 186, 108826. <https://doi.org/https://doi.org/10.1016/j.optlaseng.2025.108826>
- Zhang, W., Li, X., Xu, S., Li, X., Yang, Y., Xu, D., Liu, T., & Hu, H. (2023). Underwater Image Restoration via Adaptive Color Correction and Contrast Enhancement Fusion. *Remote Sensing*, 15(19). <https://doi.org/10.3390/rs15194699>
- Zhang, Z. (2000). A flexible new technique for camera calibration. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 22, 1330-1334. <https://doi.org/10.1109/34.888718>
- Zhou, J., et al. (2025). Probabilistic network-based method for underwater vision measurement. *Optical Engineering*, 64(2), 024105. <https://doi.org/10.1117/1.OE.64.2.024105>
- Zhou, J., Liu, Q., Jiang, Q., Ren, W., Lam, K.-M., & Zhang, W. (2023). Underwater Camera: Improving Visual Perception Via Adaptive Dark Pixel Prior and Color Correction. *International Journal of Computer Vision*, 133(11), 8215-8233. <https://doi.org/10.1007/s11263-023-01853-3>
- Zhou, J., Wang, Y., Li, C., & Zhang, W. (2023). Multicolor Light Attenuation Modeling for Underwater Image Restoration. *IEEE Journal of Oceanic Engineering*, 48(4), 1322-1337. <https://doi.org/10.1109/JOE.2023.3275615>

Appendices

A Formato y Contenido de Tesis

Declaración de Autoría

Por la presente declaro que he elaborado este documento sin la ayuda prohibida de terceros y sin hacer uso de ayudas distintas de las especificadas; nociones asumidas directamente o indirectamente de otras fuentes se han identificado como tales. Este documento no ha sido previamente presentado en forma idéntica o similar de algún otro examen nacional o extranjero.

El trabajo de tesis se llevó a cabo de **año de inicio del trabajo** a **año de término del trabajo** bajo la supervisión del Dr.**Nombre apellidos del director de tesis**.

Santiago de Querétaro, Qro., a 6 de octubre de 2026